渤海证券 Bohai Securities

基于深度学习 GRU 因子的行业轮动模型

——金融工程专题

分析师：宋旸

SAC NO：S1150517100002

2025 年 9 月 25 日

证券分析师

宋旸

022-28451131

songyang@bhzq.com

核心观点：

- 在深度学习领域，门控循环单元（Gated Recurrent Unit, GRU）与它的前身长短期记忆网络（LSTM）齐名，共同构成了处理序列数据的核心模型。GRU 通过引入“门控机制”来控制信息的流动，决定哪些历史信息应该被保留，哪些新信息应该被加入。相较于 LSTM，GRU 的结构更加简洁高效，它通过更少的门控单元实现了与 LSTM 相媲美的性能，甚至在许多场景下训练速度更快，因此受到了学术界和工业界的广泛青睐。

- 金融市场数据是典型的多变量时间序列数据，其价格走势与过去的表现密切相关。GRU 模型在处理金融时间序列时的优势体现在：1、能够自主决定将多远的历史信息传递到现在，从而捕捉到影响股价的长期趋势和周期性规律；2、可以学会忽略与预测未来无关的短期波动和市场噪音，专注于真正具有预测性的信号；3、能够有效地处理和融合这些不同时间尺度和量纲的多维输入序列，挖掘它们之间的复杂非线性关系；4、具有更快的训练速度和更低的过拟合风险。

- 本篇报告中，我们使用申万一级行业指数构建 GRU 行业轮动模型。模型输入为指数的日度量价数据，预测目标为下一期周度收益率。模型划分过去 8 年数据为训练集，第 9 年数据为验证集，第 10 年数据为测试集，每年滚动重复训练。通过回测可知，基于 GRU 预测的行业轮动模型历史 rank IC 均值 0.083。分层回测结果具有一定的分层单调性。多头（第 1 组）年化收益 3.8%，超过等权基准 2.2pct，多空年化收益 7.0%。

- 我们使用改进版的 AGRU 模型提高模型性能。AGRU 模型的核心思想是将注意力机制与标准的 GRU 模型相结合，以使模型能够动态地、有区分地关注输入序列中不同时间点的重要性。与传统 GRU 模型相比，AGRU 模型在处理股票时间序列时具有较为明显的优势。通过注意力机制，AGRU 模型可以自主学习并赋予重要时间步更高权重，根据不同市场环境（如牛市、熊市、震荡市）聚焦当时最相关的信息和因子，提升模型在不同时期的稳健性。

- AGRU 模型历史 rank IC 均值 0.084。分层回测收益表现相比 GRU 模型有了一定提升。多头（第 1 组）年化收益 6.0%，超过等权基准 4.4pct，模型多空年化收益 8.4%。通过计算 AGRU 模型合成因子与传统行业轮动模型惯用的量价、估值等因子的历史相关性数据，我们发现，AGRU 模型合成因子与传统因子相关性很低。未来可以作为行业轮动模型因子选择的一个较好补充。

- 未来，我们将持续深化 GRU 模型在行业轮动中的应用，在 GRU 模型中引入基本面、资金面、情绪面因子，并将 GRU 模型与传统行业轮动模型结合，提高现有模型的收益表现。

风险提示：市场风格转换风险，第三方数据提供不准确风险，历史结果不代表未来收益，本报告不构成投资建议。

目　录

1. GRU 模型简介 4
1.1 GRU 模型的历史 4
1.2 GRU 模型的数学原理 5
2. GRU 模型在金融市场中的应用 7
3. GRU 模型运行结果 8
4. GRU 模型的改良：AGRU 模型 10
5. AGRU 模型运行结果 11
6. 总结与未来展望 13

图 目 录

图 1：GRU 模型流程图 5
图 2：GRU 行业轮动模型历史 rank IC 值 9
图 3：GRU 行业轮动模型历史相对收益 10
图 4：AGRU 行业轮动模型历史 rank IC 值 12
图 5：AGRU 行业轮动模型历史相对收益 13
图 6：AGRU 因子历史相关性 13

表 目 录

表 1：GRU 与 LSTM 特点对比 5
表 2：GRU 行业轮动模型历史 IC 统计量 9
表 3：GRU 行业轮动模型分组收益统计 9
表 4：GRU 行业轮动模型分年度收益统计 9
表 5：AGRU 行业轮动模型历史 IC 统计量 11
表 6：AGRU 行业轮动模型分组收益统计 12
表 7：AGRU 行业轮动模型分年度收益统计 12

1. GRU 模型简介

1.1 GRU 模型的历史

序列数据广泛存在于自然语言处理、时间序列预测、语音识别等领域。传统的循环神经网络（RNN）通过其循环结构处理变长序列数据，但存在梯度消失和梯度爆炸问题，难以学习长期依赖关系。

为了解决这个问题，有研究者于 1997 年提出了长短期记忆网络（LSTM）。LSTM 通过引入一种精巧的“门控”机制和独立的“细胞状态”来有选择性地记忆和遗忘信息，从而显著缓解了梯度消失问题。

而门控循环单元（Gated Recurrent Unit, GRU）是 2014 年提出的一种先进的循环神经网络（RNN）变体。它的诞生是为了解决传统 RNN 在处理长序列数据时难以捕捉长期依赖关系的核心问题，即“梯度消失”或“梯度爆炸”问题。

在深度学习领域，GRU 与它的前身长短期记忆网络（LSTM）齐名，共同构成了处理序列数据的核心模型。GRU 通过引入“门控机制”来控制信息的流动，决定哪些历史信息应该被保留，哪些新信息应该被加入。相较于 LSTM，GRU 的结构更加简洁高效，它通过更少的门控单元实现了与 LSTM 相媲美的性能，甚至在许多场景下训练速度更快，因此受到了学术界和工业界的广泛青睐。

和 LSTM 模型相比，GRU 的主要优势包括：

1） 参数更少，训练更快，便于快速迭代和调参；
2） 模型简洁，在小型数据集上可能因不易过拟合而表现更好。

然而，GRU 也存在一些局限性，在某些需要处理非常长的时间序列，或跨度极长的依赖关系的任务中，LSTM 模型可能会表现出更强的控制能力。但实验表明 GRU 在大多数任务上与 LSTM 性能相当，在训练速度和参数效率方面更有优势。

表 1：GRU 与 LSTM 特点对比

特性	GRU	LSTM
门数量	2 个（更新门、重置门）	3 个（输入门、遗忘门、输出门）
参数数量	较少（训练更快）	较多
性能表现	适合中等长度序列	适合超长序列
细胞状态	无，直接更新隐藏状态	有细胞状态和隐藏状态双通道

资料来源：渤海证券研究所

1.2 GRU 模型的数学原理

GRU 通过“门”来控制信息的流动，决定哪些历史信息应该被保留，哪些新信息应该被加入。

GRU 单元包含两个门控结构：更新门（Update Gate）和重置门（Reset Gate）。

1) 更新门（z_t）：控制过去状态有多少信息需要传递到未来。它是 GRU 最重要的门，相当于 LSTM 中“输入门”和“遗忘门”的融合；
2) 重置门（r_t）：控制过去状态有多少信息需要被“遗忘”，以便计算新的候选激活值。它决定了如何将新的输入与过去的记忆结合。

图 1：GRU 模型流程图

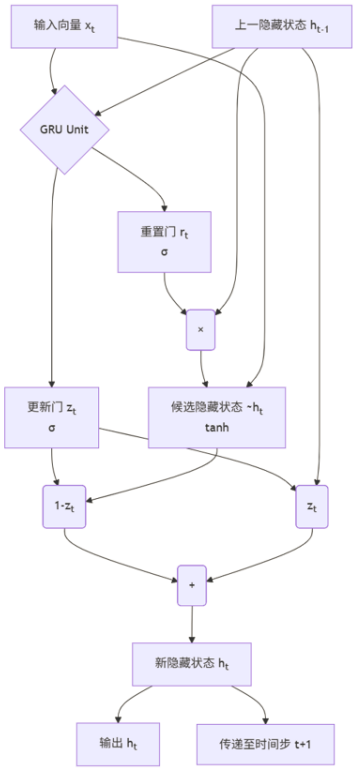

资料来源：渤海证券研究所

上图展示了一个 GRU 单元在单个时间步t内的计算流程。其输入包括：

a) 当前时间步的输入向量$\mathbf{x}_t$（例如，某只股票在当日的特征数据）；
b) 上一个时间步的隐藏状态$\mathbf{h}_{t-1}$（包含了过去的信息）。

其最终输出是新的隐藏状态$\mathbf{h}_t$，该状态既作为当前时间步的输出，也作为下一个时间步的输入。流程如下：

第 1 步：计算门控信号

两个门控并行计算，它们的作用是调控信息的流动。

a) 更新门（Update Gate）：

$$\mathbf{z}_t = \sigma(\mathbf{W}_z \cdot [\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_z)$$

决定有多少过去的信息需要被保留。$\mathbf{z}_t$值越大，保留的历史信息越多。

b) 重置门（Reset Gate）：

$$\mathbf{r}_t = \sigma(\mathbf{W}_r \cdot [\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_r)$$

决定有多少过去的信息需要被忽略，用于计算新的候选状态。$\mathbf{r}_t$值越小，忽略的历史信息越多。

第 2 步：计算候选隐藏状态

公式：

$$\tilde{\mathbf{h}}_t = \tanh(\mathbf{W} \cdot [\mathbf{r}_t \odot \mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b})$$

模型根据当前输入和经过筛选的历史信息所生成的“备选”记忆。重置门$\mathbf{r}_t$在这里起到关键作用：如果$\mathbf{r}_t$接近 0，则$\mathbf{h}_{t-1}$的影响被抑制，候选状态主要依赖于$\mathbf{x}_t$，这相当于一种“重置”机制，帮助模型丢弃无关的旧信息。

第 3 步：更新隐藏状态（最终输出）

公式：

$$\mathbf{h}_t = (\mathbf{1} - \mathbf{z}_t) \odot \tilde{\mathbf{h}}_t + \mathbf{z}_t \odot \mathbf{h}_{t-1}$$

这是 GRU 最核心的一步，它通过更新门$\mathbf{z}_t$将旧的隐藏状态和候选隐藏状态进行加权融合。

当$\mathbf{z}_t$接近 1 时，$\mathbf{h}_t$接近$\mathbf{h}_{t-1}$。这意味着单元保留了大部分历史信息，并忽略了当前的非重要输入。

当$\mathbf{z}_t$接近 0 时，$\mathbf{h}_t$接近$\tilde{\mathbf{h}}_t$。这意味着单元用新的候选状态替代了大部分旧状态，积极地吸纳新信息。

2. GRU 模型在金融市场中的应用

金融市场数据是典型的多变量时间序列数据，其特点包括：

1. **时序依赖性**：股票未来的价格走势与过去的表现密切相关；
2. **高噪声性**：市场充满大量“噪音”，有效信号容易被掩盖；
3. **长短期影响并存**：既有短期事件（如突发新闻）的影响，也受长期趋势（如宏观经济、公司基本面）的驱动。

GRU 模型在处理金融市场数据时的优势体现在：

1. **长期记忆能力**：传统的线性模型或简单 RNN 只能看到短期历史。GRU 的“更新门”能够自主决定将多远的历史信息传递到现在，从而捕捉到影响股价的长期趋势和周期性规律。
2. **噪声过滤能力**：GRU 的“重置门”可以学会忽略与预测未来无关的短期波动和市场噪音，专注于真正具有预测性的信号。这相当于一个智能过滤器，提升了模型的稳健性。
3. **对多维度特征的融合能力**：在金融模型中，我们使用的特征远不止价格和成交量，还包括技术指标、基本面数据、市场情绪数据等。GRU 能够有效地处理和融合这些不同时间尺度和量纲的多维输入序列，挖掘它们之间的复杂非线性关系。
4. **高效性**：相较于 LSTM，GRU 参数更少，结构更简单。这意味着在高频率大容量的金融数据上训练时，GRU 具有更快的训练速度和更低的过拟合风险，这对于需要快速迭代的策略研究至关重要。

假设我们要基于过去 60 个交易日的特征数据来预测下一日的股价涨跌。GRU 模型的工作流程如下：

1. **输入序列准备**：将每个股票的历史数据处理成一个序列样本，形状为$(60, n)$，其中 60 是时间步长度，n 是特征数量（如开盘价、收盘价、成交量等）；
2. **初始化**：将第一个时间步的隐藏状态$\mathbf{h}_0$初始化为零向量。
3. **循环处理**：将 60 天的数据逐日输入 GRU 单元。

   第 1 天：输入$\mathbf{x}_1$和$\mathbf{h}_0$，根据上述公式计算出$\mathbf{h}_1$；

   第 2 天：输入$\mathbf{x}_2$和上一步的$\mathbf{h}_1$，计算出$\mathbf{h}_2$；

   ...

   第 60 天：输入$\mathbf{x}_{60}$和$\mathbf{h}_{59}$，计算出最终的隐藏状态$\mathbf{h}_{60}$。此时，$\mathbf{h}_{60}$已经是一个浓缩了过去 60 天内所有有效信息的、高度抽象的表示向量。
4. **输出与预测**：将最后一个时间步的隐藏状态$\mathbf{h}_{60}$连接到一个全连接层（输出层），最终输出一个预测值。
5. **训练**：通过比较预测值与真实标签的差异（损失函数），利用反向传播算法和梯度下降优化器来更新 GRU 中的所有参数，使模型预测越来越准确。

3. GRU 模型运行结果

我们使用申万一级行业指数构建 GRU 行业轮动模型。模型输入为指数的日度量价数据，预测目标为下一期周度收益率。

模型设置如下：

数据集：2007 年至今 30 个申万一级行业（剔除综合）的日度数据；

特征量：过去 1/5/20 日指数的最高价、开盘价、最低价、收盘价、成交量、换手率、动量、波动率、RSI、MACD 数据，进行横截面标准化；

输入数据：过去 60 日特征向量；

预测目标：未来一周收益率（横截面标准化）；

数据集划分：划分过去 8 年数据为训练集，第 9 年数据为验证集，第 10 年数据为测试集。每年滚动重复训练；

损失函数：MSE；

优化器：Adam；

学习率：0.001；

早停机制：验证集 loss 连续 10 轮未能更小，停止训练。

通过回测可知，基于 GRU 预测的行业轮动模型历史 rank IC 均值 0.083。分层回测具有一定的分层单调性。多头（第 1 组）年化收益 3.8%，超过等权基准 2.2pct，多空年化收益 7.0%。

表 2：GRU 行业轮动模型历史 IC 统计量

	t 值绝对值平均值	t 值绝对值>2 概率	IC 平均值	IC 标准差	IR	IC>0 概率
predicted	1.132	0.152	0.083	0.190	0.436	69.2%

资料来源：iFind，渤海证券研究所

图 2：GRU 行业轮动模型历史 rank IC 值

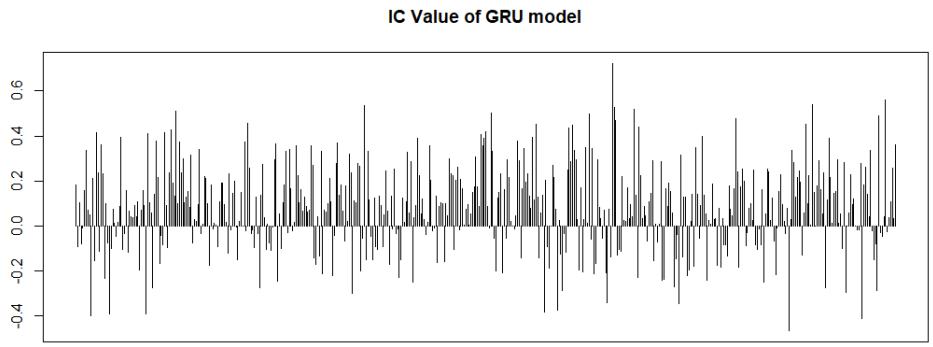

资料来源：iFind，渤海证券研究所

表 3：GRU 行业轮动模型分组收益统计

	gp1	gp2	gp3	gp4	gp5	等权
累计收益	42.8%	20.7%	27.0%	18.1%	-26.4%	15.8%
年化收益	3.8%	2.0%	2.6%	1.8%	-3.2%	1.6%
波动率	21.3%	21.1%	21.2%	21.5%	21.5%	20.4%
最大回撤	30.4%	37.3%	38.5%	41.6%	54.3%	36.6%
夏普比率	0.180	0.095	0.120	0.082	-0.148	0.076
信息比率	0.350	0.074	0.170	0.034	-0.759	--
胜率	51.7%	49.9%	49.1%	50.1%	45.6%	--

资料来源：iFind，渤海证券研究所

表 4：GRU 行业轮动模型分年度收益统计

	gp1	gp2	gp3	gp4	gp5	等权
2016	-4.8%	9.9%	-7.7%	-4.5%	-3.3%	-2.2%
2017	7.8%	-0.1%	1.1%	2.4%	5.1%	3.3%
2018	-18.7%	-32.6%	-32.0%	-28.8%	-29.5%	-28.4%
2019	25.8%	23.9%	30.3%	27.5%	17.3%	25.0%
2020	21.4%	15.9%	32.9%	35.8%	19.1%	25.0%

2021	12.4%	6.6%	-0.2%	4.5%	0.8%	5.1%
2022	-9.1%	-14.1%	-4.1%	-10.4%	-15.9%	-10.6%
2023	-8.2%	-8.5%	-10.2%	-15.6%	-26.1%	-13.9%
2024	-2.2%	12.9%	12.1%	3.7%	0.8%	5.5%
2025	22.2%	20.2%	20.0%	19.6%	16.4%	19.8%

资料来源：iFind，渤海证券研究所

图 3：GRU 行业轮动模型历史相对收益

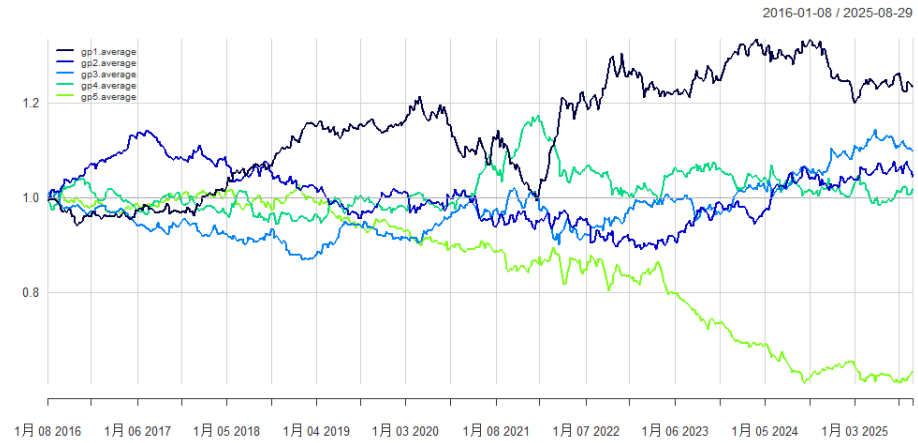

资料来源：iFind，渤海证券研究所

4. GRU 模型的改良：AGRU 模型

我们尝试使用改进版的 AGRU 模型提高模型性能。AGRU（Attention-based Gated Recurrent Unit）模型的核心思想是将注意力机制（Attention Mechanism）与标准的 GRU 模型相结合，以使模型能够动态地、有区分地关注输入序列中不同时间点的重要性。

在实践中，AGRU 模型将注意力机制融入 GRU 的更新过程，模型会通过深度学习计算每个历史时间步的注意力分数，这些分数代表了每个历史信息相对于当前预测的重要程度。再使用注意力分数增强原有的门控机制。

注意力增强的更新门:

$$\mathbf{z}'_t = \mathbf{a}_t \cdot \mathbf{z}_t + (1 - \mathbf{a}_t) \cdot \ \mathbf{z}_{t-1}$$

注意力引导的隐藏状态更新:

$$\mathbf{h}_t = (\mathbf{1} - \mathbf{z}'_t) \odot \mathbf{h}_{t-1} + \mathbf{z}'_t \odot \tilde{\mathbf{h}}_t + \beta \cdot \mathbf{a}_t \cdot \mathbf{c}_t$$

其中，$\mathbf{c}_t$为上下文向量，β为注意力强度系数。

与传统 GRU 模型相比，AGRU 模型在处理金融时间序列时具有更为明显的优势：

1. **精准捕捉关键事件：**普通 GRU 模型在运行时平等地处理所有历史信息，或者通过门控进行被动遗忘。但在 AGRU 模型中，通过注意力机制能自主学习并赋予重要时间步更高权重，更有效捕捉这些具有预测价值的长程依赖和关键节点。
2. **动态适应市场变化：**市场的驱动因素和主导风格会变化。AGRU 的注意力权重能够动态调整，根据不同市场环境（如牛市、熊市、震荡市）聚焦当时最相关的信息和因子，提升模型在不同时期的稳健性。
3. **有效过滤噪声：**金融市场数据噪声极大。大部分时间的微小波动对预测未来价值不大。注意力机制充当了一个强大的噪声过滤器。模型学会给信息量大的时间点分配高权重，而给噪声大的时间点分配低权重甚至忽略它们。这使得模型更加专注于高质量的信号。

5. AGRU 模型运行结果

AGRU 行业轮动模型参数设置与 GRU 模型类似。AGRU 模型历史 rank IC 均值 0.084。分层回测收益表现相比 GRU 模型有了一定提升。多头（第 1 组）年化收益 6.0%，超过等权基准 4.4pct，模型多空年化收益 8.4%。

表 5：AGRU 行业轮动模型历史 IC 统计量

	t 值绝对值平均值	t 值绝对值>2 概率	IC 平均值	IC 标准差	IR	IC>0 概率
predicted	1.177	0.170	0.084	0.203	0.414	65.5%

资料来源：iFind，渤海证券研究所

图 4：AGRU 行业轮动模型历史 rank IC 值

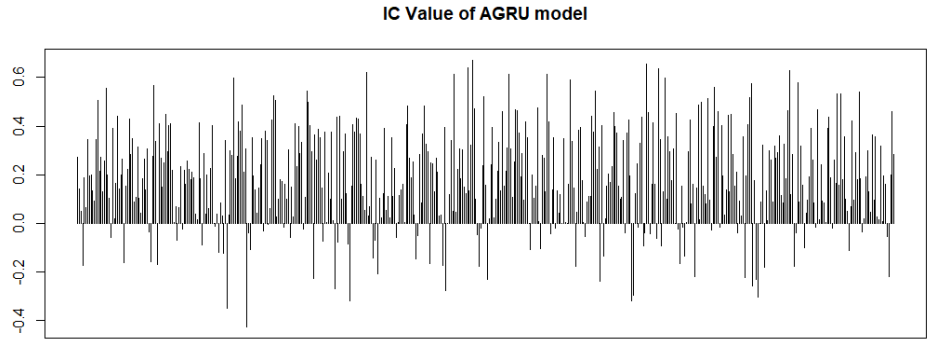

资料来源：iFind，渤海证券研究所

表 6：AGRU 行业轮动模型分组收益统计

	gp1	gp2	gp3	gp4	gp5	等权
累计收益	73.8%	20.7%	12.7%	0.8%	-20.8%	15.8%
年化收益	6.0%	2.0%	1.3%	0.1%	-2.4%	1.6%
波动率	21.5%	21.4%	21.5%	21.5%	21.0%	20.4%
最大回撤	38.0%	44.4%	34.2%	41.6%	46.9%	36.6%
夏普比率	0.279	0.094	0.059	0.004	-0.116	0.076
信息比率	0.693	0.068	-0.046	-0.220	-0.672	--
胜率	53.1%	48.9%	47.9%	48.5%	44.4%	--

资料来源：iFind，渤海证券研究所

表 7：AGRU 行业轮动模型分年度收益统计

	gp1	gp2	gp3	gp4	gp5	等权
2016	-2.5%	-1.0%	-6.1%	-2.2%	0.6%	-2.2%
2017	12.8%	1.9%	7.2%	-1.8%	-3.4%	3.3%
2018	-21.6%	-30.4%	-29.4%	-28.4%	-32.3%	-28.4%
2019	34.9%	24.1%	20.5%	31.7%	14.2%	25.0%
2020	27.9%	33.0%	16.0%	32.3%	15.4%	25.0%
2021	11.1%	-2.1%	13.3%	-3.4%	6.0%	5.1%
2022	-13.1%	-7.4%	-6.5%	-14.3%	-12.5%	-10.6%
2023	-13.7%	-17.2%	-15.6%	-12.5%	-11.0%	-13.9%
2024	8.9%	10.2%	12.9%	0.1%	-4.8%	5.5%
2025	28.7%	25.9%	12.2%	16.0%	16.2%	19.8%

资料来源：iFind，渤海证券研究所

图 5：AGRU 行业轮动模型历史相对收益

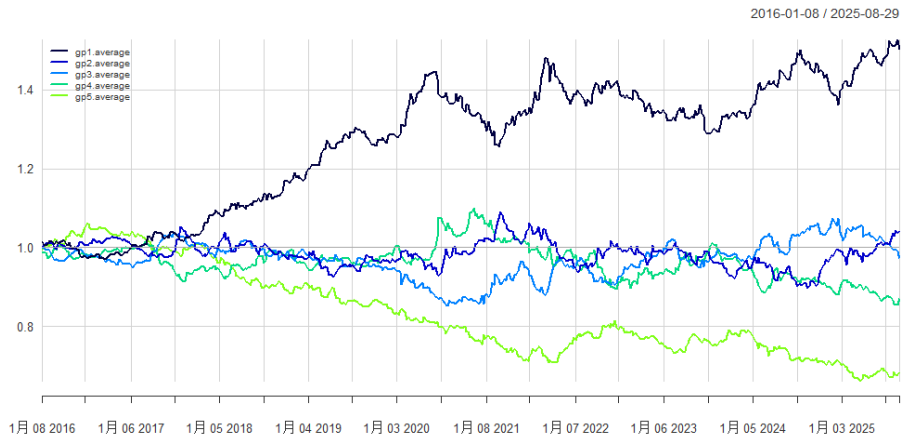

资料来源：iFind，渤海证券研究所

通过计算 AGRU 模型合成因子与传统行业轮动模型惯用的量价、估值等因子的历史相关性数据，我们发现，AGRU 模型合成因子与传统因子相关性很低。未来可以作为行业轮动模型因子选择的一个较好补充。

图 6：AGRU 因子历史相关性

	agru	pe_ttm	mom	vol	rsi
agru	1.00	0.14	0.12	0.12	0.12
pe_ttm	0.14	1.00	0.23	0.23	0.23
mom	0.12	0.23	1.00	0.25	0.68
vol	0.12	0.23	0.25	1.00	0.24
rsi	0.12	0.23	0.68	0.24	1.00

资料来源：iFind，渤海证券研究所

6. 总结与未来展望

本篇报告中，我们使用申万一级行业指数构建 GRU 行业轮动模型。模型输入为指数的日度量价数据，预测目标为下一期周度收益率。模型划分过去 8 年数据为训练集，第 9 年数据为验证集，第 10 年数据为测试集。每年滚动重复训练。

通过回测可知，基于 GRU 预测的行业轮动模型历史 rank IC 均值 0.083。分层回测具有一定的分层单调性。多头（第 1 组）年化收益 3.8%，超过等权基准 2.2pct，多空年化收益 7.0%。

我们使用改进版的AGRU模型提高模型性能。AGRU模型历史rank IC均值0.084。分层回测收益表现相比GRU模型有了一定提升。多头（第1组）年化收益6.0%，超过等权基准4.4pct，模型多空年化收益8.4%。通过计算AGRU模型合成因子与传统行业轮动模型惯用的量价、估值等因子的历史相关性数据，我们发现，AGRU模型合成因子与传统因子相关性很低。未来可以作为行业轮动模型因子选择的一个较好补充。

未来，我们将持续深化GRU模型在行业轮动中的应用，在GRU模型中引入基本面、资金面、情绪面因子。并将GRU模型与传统行业轮动模型结合，提高现有模型的收益表现。

风险提示：

1、**市场风格转换风险：**未来如果发生市场波动和市场风格转换，模型可能失效。
2、**第三方数据提供不准确风险：**模型数据来源为公开的历史数据，可能存在第三方数据提供不准确风险。
3、**历史结果不代表未来收益：**模型基于历史规律总结，历史结果不代表未来收益。

本报告不构成投资建议。

分析师声明：

本报告署名分析师在此声明：我们具有中国证券业协会授予的证券投资咨询执业资格并登记为证券分析师，以勤勉尽责的职业态度、专业审慎的研究方法，使用合法合规的数据和信息，独立、客观地出具本报告；本报告所表述的任何观点均精准地、如实地反映研究人员的个人观点，结论不受任何第三方的授意或影响。我们所获取报酬的任何部分无论是在过去、现在及将来均不会与本报告中的具体投资分析意见或观点有直接或间接的联系。

风险提示及免责声明：

投资者应自主作出投资决策并自行承担投资风险，任何形式的分享证券投资收益或者分担证券投资损失的书面或口头承诺均为无效。

本报告由渤海证券股份有限公司（以下简称“本公司”）制作，仅供本公司的客户使用。发送本报告不构成任何合同或承诺的基础，不因接收者收到本报告而视其为本公司客户。本报告仅在相关法律许可的情况下发送，并仅为提供信息而发送，不构成任何广告。

本报告的信息来源于已公开的资料，本公司对该等信息的准确性、完整性或可靠性不作任何保证，不保证该信息未经任何更新。本报告所载的资料、意见及推测仅反映本公司于发布本报告当日的判断，本报告所指的证券或投资标的的价格、价值及投资收入可升可跌。过往表现不应作为日后表现的依据。在不同时期，本公司可发出与本报告所载资料、意见及推测不一致的报告。本公司不保证本报告所含信息保持在最新状态。同时，本公司对本报告所含信息可在不发出通知的情形下做出修改，投资者应当自行关注相应的更新或修改。

在任何情况下，本报告内容的全部或部分均不构成对任何人的投资建议。本报告中所指的投资及服务可能不适合个别客户，不构成客户私人咨询建议。在任何情况下，本公司、本公司员工或者关联机构不承诺投资者一定获利，不与投资者分享投资收益，也不对任何人因使用本报告中的任何内容所引致的任何损失负任何责任。投资者务必注意，其据此做出的任何投资决策与本公司、本公司员工或者关联机构无关。在任何情况下，本公司、本公司员工或者关联机构不就本报告中的任何内容对任何投资做出任何形式的担保。

在所知情的范围内，本公司、本报告撰写人以及财产上的利害关系人与本报告所评价或作出明确估值和投资评级的证券无利害关系。本公司利用信息隔离墙控制内部一个或多个领域、部门或关联机构之间的信息流动。因此，投资者应注意，在法律许可的情况下，本公司及其所属关联机构可能持有并交易本报告中所提公司的股份或其他财产权益，也可能为这些公司提供或者争取提供投资银行、财务顾问或者金融产品等相关服务。

市场有风险，投资需谨慎。投资者不应将本报告作为作出投资决策的唯一参考因素，亦不应认为本报告可以取代自己的判断。在决定投资前，如有需要，投资者务必向专业人士咨询并谨慎决策。

本报告版权为本公司所有。未经本公司事先书面许可，任何机构和/或个人不得以任何形式刊载、转发、翻版、复制、发布或引用本报告全部或部分内容，亦不得从未经本公司书面授权的任何机构、个人或其运营的媒体平台接收、翻版、复制或引用本报告全部或部分内容。如征得本公司同意进行引用、刊载或转发的，需在允许的范围内使用，并注明出处为“渤海证券股份有限公司”且不得对本报告进行任何有悖原意的引用、删节和修改。

若本公司以外的其他机构（以下简称“该机构”）发送本报告，则由该机构独自为此发送行为负责。通过此途径获得本报告的投资者应自行联系该机构以要求获悉更详细信息或进而交易本报告中提及的证券。本报告不构成本公司向该机构之客户提供的投资建议，本公司、本公司员工或者关联机构亦不为该机构之客户因使用本报告或报告所载内容引起的任何损失承担任何责任。

投资评级说明：

项目名称	投资评级	评级说明
公司评级标准	买入	未来 6 个月内相对沪深 300 指数涨幅超过 20%
	增持	未来 6 个月内相对沪深 300 指数涨幅介于 10%~20%之间
	中性	未来 6 个月内相对沪深 300 指数涨幅介于-10%~10%之间
	减持	未来 6 个月内相对沪深 300 指数跌幅超过 10%
行业评级标准	看好	未来 12 个月内相对于沪深 300 指数涨幅超过 10%
	中性	未来 12 个月内相对于沪深 300 指数涨幅介于-10%-10%之间
	看淡	未来 12 个月内相对于沪深 300 指数跌幅超过 10%

渤海证券研究所机构销售团队：

高级销售经理：朱艳君
座机：+86 22 2845 1995
手机：135 0204 0941
邮箱：zhuyanjun@bhzq.com

高级销售经理：王文君
座机：+86 10 6810 4637
手机：186 1170 5783
邮箱：wangwj@bhzq.com

天津：
天津市南开区水上公园东路宁汇大厦 A 座写字楼
邮政编码：300381
电话：+86 22 2845 1888
传真：+86 22 2845 1615

北京：
北京市西城区西直门外大街甲 143 号 凯旋大厦 A 座 2 层
邮政编码：100086
电话：+86 10 6810 4192
传真：+86 10 6810 4192

渤海证券股份有限公司网址： www.ewww.com.cn