高维环境下的最优因子择时

——量化研究参考系列之三

报告发布日期 2026 年 04 月 21 日

证券分析师

刘静涵 执业证书编号：S0860520080003
香港证监会牌照：BSX840
liujinghan@orientsec.com.cn
021-63326320

相关报告

DFQ - TimesNet：捕捉量价特征周期规律，提升股票收益预测效果：——因子选股系列之一一八 2026-04-16
SSPT：股票时序定制化预训练选股框架：——量化研究参考系列之二一 2026-04-13
QuantaAlpha: 用大模型做量化因子挖掘：——量化研究参考系列之一 2026-04-07

研究结论

- **文献信息：** 本次分享的论文由 Northern Trust Asset Management 的 Rob Lehnherr（CFA）、Manan Mehta 以及芝加哥大学 Booth 商学院的 Stefan Nagel 联合撰写，于 2025 年 3 月发表于 Financial Analysts Journal, 81(2): 51-66，**标题为《Optimal Factor Timing in a High-Dimensional Setting》高维环境下的最优因子择时。**
- **推荐理由：** 多因子择时在实践中一直较难实现，核心原因有两点：其一，已有研究大多只使用一到两个预测信号，难以充分捕捉因子收益的变化规律；其二，当因子数量和预测变量数量同时上升时，优化过程很容易被历史噪声误导。本文将宏观变量与因子特有变量同时纳入统一的组合优化框架，并通过三层收缩机制逐级控制估计误差。实证结果显示，择时策略的夏普比率相对等权策略大致翻倍，相对静态最优策略稳定提升约 0.25 至 0.30，扣除交易成本后仍具有较强的经济意义。
- **核心框架：** 1）将每个因子的月收益与上月末的预测信号值相乘，构造出一批择时组合。由于信号值在构造时点已知，这些组合的收益可以被视为普通收益序列，原本需要每月重新求解的动态调仓问题，由此转化为对全部择时组合寻找固定权重的静态均值方差优化问题。2）引入三层收缩机制：Ledoit-Wolf 协方差收缩用于提升协方差矩阵估计的稳定性，权重收缩用于将择时权重向静态策略方向压缩，因子轮动约束用于固定总敞口，避免出现极端杠杆。3）采用扩展窗口训练和累积式验证集来调优收缩参数 λ，尽量避免前瞻偏差。4）实证上分别测试了 Fama-French（2015）五因子模型中的四个非市场因子、大盘版因子，以及 Jensen 等提出的 131 个因子，覆盖从低维到高维的完整测试梯度。
- **亮点分析：** 相较于已有因子择时研究，本文主要有三点突破：1）从单因子单信号的经验规则，升级为多因子多信号的统一组合优化框架：将因子收益与滞后信号相乘构造择时组合，把动态调仓问题转化为标准的均值方差优化，宏观变量与因子特有变量两类信号在其中共同提供互补的择时信息。2）通过数据驱动的三层收缩机制控制高维过拟合，在保留全部信号的同时自适应调节模型对择时信号的信任程度，同时显著降低换手率。3）验证了大盘股因子同样存在显著择时空间，说明择时收益并非仅由小盘股驱动。
- **实证结果：** 样本外区间为 1986 年至 2022 年。无论因子数量多少，择时策略相对静态最优策略的夏普比率增量均稳定在 0.25 至 0.30 之间，相对等权策略则基本实现夏普比率翻倍。具体来看，FF 四因子择时策略的样本外夏普比率为 0.81，大盘版因子为 0.56，Jensen 等 131 因子为 1.48。扣除交易成本后，策略夏普比率仍显著优于基准组合。
- **优化方向：结合 A 股市场特性，可从四个方向推进本土化落地：** 1）在预测变量中纳入社融、北向资金、两融余额及因子拥挤度等更具 A 股特色的信号。2）加入平方项、交叉项或状态依赖模型，增强对风格切换非线性特征的刻画能力。3）构建适用于 A 股的本土化因子池，并在择时前进行行业和市值中性化处理。4）优化收缩参数 λ 的验证框架，同时进一步控制换手率和交易成本。

风险提示

1. 量化模型基于历史数据分析，未来存在失效风险，建议持续跟踪模型表现。
2. 极端市场环境可能对模型效果造成显著冲击，导致收益回撤。
3. 论文实证基于美股数据，迁移至 A 股时需充分考虑市场结构和交易制度差异。
4. 因子择时策略涉及动态调仓，交易成本和流动性约束可能侵蚀部分理论收益。
5. 收缩参数 λ 的选择依赖于验证集设计，若验证集设置不当可能导致收缩不足或过度，影响策略稳健性。

有关分析师的申明，见本报告最后部分。其他重要信息披露见分析师申明之后部分，或请与您的投资代表联系。并请阅读本证券研究报告最后一页的免责申明。

目 录

1、 文献信息：芝加哥大学 Nagel 等发表于 FAJ，2025 年 3 月正式刊出.....4

2、 推荐理由：多预测变量与权重收缩，系统性破解因子择时难题 4

3、 核心框架：从时序预测到截面优化，三层收缩保障高维稳健性 4

3.1 三档因子与两类预测信号覆盖从低维到高维的完整测试梯度.....5
3.2 择时组合构造与优化：将动态调仓问题转化为静态均值方差优化.....6

3.2.1 为什么不能直接优化因子权重 6

3.2.2 择时组合的定义与直觉 6

3.2.3 从择时组合到均值方差优化 7

3.2.4 从 48 维权重还原为因子配置 7

3.3 三层收缩机制：抑制高维环境下的过拟合风险 8
3.4 实证实施：扩展窗口训练与验证集超参数调优 9

4、 亮点分析：相较已有因子择时方法的主要突破 9

4.1 从单一信号扩展到多维信号融合.....9
4.2 将因子择时直接改写为组合优化问题.....10
4.3 高维组合优化框架内引入数据驱动的收缩机制 10
4.4 验证了大盘股因子同样存在显著的择时空间.....10

5、 实证结果：样本外夏普比率显著提升，择时策略表现稳健 11

5.1 三档因子集合样本外表现：择时策略一致跑赢静态基准 11
5.2 收缩显著降低换手率，扣费后策略仍优于基准 13

6、 改进方向：贴合 A 股特性，多维度升级实现本土化落地.....14

6.1 丰富预测变量体系，融入 A 股特色信号.....14
6.2 引入非线性模型扩展择时能力 14
6.3 构建 A 股因子池并适配因子构造方式 15
6.4 缩短验证窗口并纳入换手率约束，适配 A 股风格切换节奏 15

7、 风险提示 15

有关分析师的申明，见本报告最后部分。其他重要信息披露见分析师申明之后部分，或请与您的投资代表联系。并请阅读本证券研究报告最后一页的免责申明。

图表目录

图 1：Fama-French 四因子及预测变量汇总.....5
图 2：训练、验证与样本外期间划分：扩展窗口训练 + 滚动验证集调优超参数.....9
图 3：消融实验汇总——信号融合与收缩机制的边际贡献.....10
图 4：Fama-French 因子组合样本外夏普比率（60 月滚动窗口）：择时策略几乎全程跑赢.....11
图 5：择时策略对 Fama-French 四因子的隐含权重变化：1999/2007/2020 年主动降低价值因子敞口.....12
图 6：大盘版因子样本外夏普比率（60 月滚动窗口）：择时仍实现夏普比率翻倍.....12
图 7：Jensen 等因子样本外夏普比率（60 月滚动窗口）：高维设定下夏普比率达 1.48.....13
图 8：交易成本调整后表现：Jensen 等因子择时扣费后夏普比率仍达 1.31-1.35，收缩显著降低换手率.....14

有关分析师的申明，见本报告最后部分。其他重要信息披露见分析师申明之后部分，或请与您的投资代表联系。并请阅读本证券研究报告最后一页的免责申明。

量化投资行业前沿理论与技术迭代提速，海外顶尖量化研究成果中蕴藏着诸多可借鉴的新思路、新框架，为 A 股量化因子挖掘与策略研发提供重要参考。为此，我们推出量化研究参考系列报告，聚焦海外顶刊、预印本平台发布的量化领域前沿文献，通过深度拆解核心逻辑、实证结果与创新价值，结合 A 股市场特性及本土投研实践开展适配性分析，提炼可落地的优化方向与应用思路，为投资者提供专业、前沿的研究参考。**本期为系列第三篇，重点解读发表于 Financial Analysts Journal 的因子择时前沿论文，探讨在高维环境下如何通过多预测变量与权重收缩框架实现系统性的最优因子择时。**

1、 文献信息：芝加哥大学 Nagel 等发表于 FAJ，2025 年 3 月正式刊出

本次分享的论文由 Northern Trust Asset Management 的 Rob Lehnherr（CFA）、Manan Mehta 以及芝加哥大学 Booth 商学院的 Stefan Nagel 联合撰写，于 2025 年 3 月发表于 Financial Analysts Journal, 81(2): 51-66，标题为**《Optimal Factor Timing in a High-Dimensional Setting》高维环境下的最优因子择时**。

2、 推荐理由：多预测变量与权重收缩，系统性破解因子择时难题

多因子策略通常以固定比例配置各风格因子（如价值、动量、盈利等）。但因子表现在不同时期差异很大，价值因子可能连续两三年跑输，动量因子也会阶段性失效。因子择时的目标，就是根据宏观经济指标、因子自身近期表现等可观测信号，动态调整各因子的配置权重：对预期将走强的因子加仓，对预期将走弱的因子减仓。然而，过去二十年的研究反复表明，因子择时在实践中非常困难，已有方法的样本外表现普遍不理想。核心原因在于两点：一是大多数研究只用一到两个预测信号，信号来源单一，难以充分捕捉因子收益的变化规律；二是当因子和预测变量的数量同时增加时，优化过程极易被历史数据中的噪声误导，导致样本外表现快速退化。

本文针对上述两个难题，提出了一套系统性的解决方案。在信号维度上，论文将宏观变量与因子特有变量同时纳入一个统一的组合优化框架，显著拓宽了择时信号的来源。在过拟合抑制上，论文引入了三层收缩机制，从协方差估计、权重估计和仓位约束三个层面逐级控制高维环境下的估计误差。实证结果显示，无论因子规模大小，择时策略的夏普比率都相对等权策略大致翻倍，相对静态最优策略则稳定提升约 0.25 至 0.30，扣除交易成本后仍具有经济意义。该框架对 A 股量化研究同样具有借鉴价值，具体的本土化落地方向详见第六部分。

3、 核心框架：从时序预测到截面优化，三层收缩保障高维稳健性

为便于理解后续方法论的讨论，此处先简要说明因子、因子组合与因子择时三者之间的关系。因子本质上是一个股票的多空组合，按某个特征（如估值高低）将股票分为两组，做多一组、做空另一组。因子组合则是将多个这样的多空组合按一定权重加总在一起。因子择时所做的事情，就是每个月根据可观测的信号，动态调整各因子之间的权重分配，对预期将走强的因子加仓，对预期将走弱的因子减仓或反向配置。论文的核心框架可拆解为四个环节，环环相扣。

有关分析师的申明，见本报告最后部分。其他重要信息披露见分析师申明之后部分，或请与您的投资代表联系。并请阅读本证券研究报告最后一页的免责申明。

3.1 三档因子与两类预测信号覆盖从低维到高维的完整测试梯度

为便于理解后续方法论，先说明论文使用的因子集合与预测变量。

因子方面，论文设置了三档集合以检验框架在不同规模下的适用性。第一档为 Fama-French（2015）五因子模型中的四个非市场因子：规模（SMB）、价值（HML）、盈利能力（RMW）和投资（CMA）。第二档仅使用 NYSE 市值中位数以上的大盘股构造因子，用以检验择时收益是否依赖于小盘股的流动性溢价。第三档为 Jensen, Kelly and Pedersen（2023）因子库中的 131 个因子，代表高维大规模设定。

预测变量分为两类。第一类为 5 个宏观变量：实际利率、收益率曲线斜率、利率变化、近三个月市场收益和信用利差，主要反映宏观经济周期与市场整体风险偏好的变化。第二类为 6 个因子特有变量：因子近期收益（3 个月和 12 个月）、3 个月日频波动率，以及因子多空两端的特征差值（账面市值比、资产增长率、盈利能力），主要反映各因子自身的近期动态与相对估值状态。论文还额外加入一个恒等于 1 的常数项，使得因子原始收益本身也被纳入后续优化框架，其作用将在 3.2 中说明。所有预测变量在每月末基于截至当期的历史数据标准化为 z-score（即减去历史均值再除以历史标准差，使不同变量处于可比尺度），确保变量尺度一致并严格避免前瞻偏差（图 1）。

三档因子集合与两类预测变量的不同组合，构成了后文实证分析从小规模到高维度的完整测试梯度，具体维度将在 3.2 中随方法论一并说明。

图 1：Fama-French 四因子及预测变量汇总

Table 1. Small Set of Factors and Predictors

Panel A: Fama-French Factor Returns

	Mean	Std. Dev.	Sharpe Ratio
Size	0.41	10.65	0.04
B/M	2.16	10.91	0.20
Investment	3.39	7.30	0.46
Profitability	4.56	8.73	0.52

Panel B: Predictor Variables

Macro variables	*Factor-specific variables*
Real 1y yield	3m factor return
Yield slope (5y-1y)	12m factor return
12m change in 1y yield	3m daily factor volatility
3m CRSP vw. index return	B/M spread
Baa-Treasury spread	Asset growth spread
	Profitability spread

Notes: Means, standard deviations, and Sharpe ratios are annualized. Means and standard deviations are shown in percentages. The sample period for the Fama-French factor return statistics is January 1986 to 2022, the same period that we use for out-of-sample analysis in our empirical work.

数据来源：东方证券研究所 &《Optimal Factor Timing in a High-Dimensional Setting》

有关分析师的申明，见本报告最后部分。其他重要信息披露见分析师申明之后部分，或请与您的投资代表联系。并请阅读本证券研究报告最后一页的免责申明。

3.2 择时组合构造与优化：将动态调仓问题转化为静态均值方差优化

3.2.1 为什么不能直接优化因子权重

因子择时的思路是：每个月根据最新信号预测各因子的下期收益，再用这些预测值做一次组合优化，得到当月的因子配置权重。然而这条路在实践中面临根本性困难。由于条件期望随信号变化，每个月面对的都是一个不同的优化问题，不存在一组可以跨时间复用的固定参数。同时，预测与优化两步嵌套，第一步的预测误差会在第二步被放大，当预测变量较多时尤为严重。论文采用了一种不同的策略：不显式预测因子收益，而是通过构造“择时组合”，将整个问题一次性转化为一个标准的静态均值方差优化。

上述困难的根源可以从数学角度更清晰地理解。假设投资者每月需要确定四个因子各自的配置权重，且希望这些权重能够利用当期可观测的预测信号。形式上，这等价于为每个因子 i寻找一个权重映射函数 $\phi_i(\cdot)$，使得其在 t月的权重满足：

$$h_i(t) = \phi_i\left(z_{0,t-1}, z_{1,t-1}, \dots, z_{J,t-1}\right)$$

其中，$z_{0,t-1} \equiv 1$ 为常数项，$z_{1,t-1}$ 到 $z_{J,t-1}$为 $t-1$月末可观测的 J个预测信号。若对 ϕ_i的函数形式不加约束，投资者原则上可以为任意一种信号组合分别指定不同的权重向量，这样的问题很难从有限的历史样本中稳定估计。论文的关键设定是将 ϕ_i限定为线性函数。在线性设定下，因子 i的权重可以写为：

$$h_i(t) = \sum_{k=0}^{J} w_{i,k}\, z_{k,t-1} = w_{i,0} \cdot 1 + \sum_{k=1}^{J} w_{i,k}\, z_{k,t-1}$$

其中，$w_{i,k}$ 为待估的固定线性系数。以 FF 四因子搭配 11 个预测信号和 1 个常数项为例，每个因子对应 12 个系数，合计需要估计 $4 \times 12 = 48$个参数。这些系数在一次训练窗口内保持固定，因子权重 $h_i(t)$的月度变化则来自信号 $z_{k,t-1}$的变化。线性设定由此将原本形式不确定的动态权重问题转化为一组固定参数的估计问题。论文进一步表明，这些参数的估计可以被改写为一个标准的均值方差优化问题，这正是下文“择时组合”构造的出发点。

3.2.2 择时组合的定义与直觉

对每个因子 i 和每个预测信号 k，论文定义一个“择时组合”，其第 t 月的收益为：

$$g_{ik,t} = z_{k,t-1} \cdot f_{i,t}$$

其中的 · 不是矩阵乘法，也不是向量点积，是逐对相乘。$f_{i,t}$ 是一个数值，代表因子 i 在第 t 月的收益，$z_{k,t-1}$ 也是一个数值，代表第 k 个预测信号在 t-1 月末的标准化值。两者相乘，得到一个数值$g_{ik,t}$。由于 $z_{k,t-1}$ 在 t-1 月末已经确定，这个乘积可以理解为：在 t-1 月末观察到信号值后，对因子 i 施加一个与信号大小成比例的暴露，并在 t 月获得相应收益。若信号为正，则对该因子保持正向配置；若信号为负，则自动转为反向配置。若该信号对因子收益没有预测力，择时组合收益的正负会随机抵消，长期均值趋近于零，不会凭空产生收益；只有当信号与未来因子表现存在稳定关系时，对应的择时组合才会表现出显著的正均值。需要注意的是，$z_{k,t-1}$ 仅使用 t-1 月末及之前的信息，$f_{i,t}$ 是 t 月的实现值，构造过程不涉及任何未来数据。

有关分析师的申明，见本报告最后部分。其他重要信息披露见分析师申明之后部分，或请与您的投资代表联系。并请阅读本证券研究报告最后一页的免责申明。

3.1 中提到的常数项在此处发挥关键作用。令第 0 个预测信号恒等于 1（$z_{0,t-1} \equiv 1$），则对应的择时组合收益 $g_{i0,t} = f_{i,t}$，即因子 i 的原始收益。这保证了因子本身始终作为优化对象的一部分——即使所有择时信号都被证明无效，优化结果仍可退化为一个不做择时的静态因子组合。

以 Fama-French 四因子搭配小预测集为例：4 个因子，每个因子对应 11 个预测变量加 1 个常数项共 12 维，合计 4 × 12 = 48 个择时组合。当因子扩展至 Jensen 等（2023）的 131 个时，同样的 12 个预测维度对应 131 × 12 = 1,572 个择时组合。论文还测试了大预测集（将预测变量从 11 个扩展至 138 个，加上常数项共 139 维），此时 131 个因子对应 131 × 139 = 18,209 个择时组合。

3.2.3 从择时组合到均值方差优化

全部择时组合的月度收益可以排成一个向量 g_t（以 FF 四因子为例为 48×1）。利用训练期的历史数据，可以估计两组关键统计量：均值向量 $\hat{\mu}$（48×1），反映每个择时组合在训练期内的平均获利能力；协方差矩阵 $\hat{\Sigma}$（48×48），反映各择时组合之间的风险联动结构（$\hat{\Sigma}$ 的具体估计方法涉及第一层收缩，详见 3.3）。

优化目标是在所有 48 个择时组合中，寻找一组权重 w（48×1），使加权组合的夏普比率最大化。这是一个标准的均值方差优化问题，在不施加额外收缩的情况下，最优权重方向与 $\hat{\Sigma}^{-1}\hat{\mu}$ 成正比，再经归一化后得到最终权重:

$$w \propto \hat{\Sigma}^{-1}\hat{\mu}$$

需要准确理解“静态”一词的含义。在一次给定的训练窗口内，优化得到的是一组固定的择时组合权重；随着扩展窗口向前滚动（详见 3.4），这组权重会基于更长的训练数据重新估计；而每月真正执行的因子权重则会随当期信号值变化——这一点在下文说明。

上述解析形式在择时组合数量较少时可以正常工作，但当组合从 48 个扩展到数千乃至上万个时，$\hat{\mu}$ 和 $\hat{\Sigma}$ 中的估计误差会主导优化结果，导致样本外表现迅速退化。论文为此设计了三层收缩机制来规训权重估计，详见 3.3。

3.2.4 从 48 维权重还原为因子配置

优化给出的 w 是 48 维（或更高维），对应每个择时组合的权重。要在实盘中执行，需要将其还原为对每个因子的实际配置权重。方法是将同一因子对应的所有择时组合贡献加总。将 48 维权重向量 w 的每个元素按“因子 i × 信号 k”的对应关系标记为 w_{ik}，则因子 i 在 t 月的隐含权重为：

$$h_{i,t} = \sum_k w_{ik} \cdot z_{k,t-1}$$

即把因子 i 所对应的全部 12 个择时组合权重，分别乘以对应的 t-1 月末信号值，再求和。以价值因子（HML）为例：它对应 12 个择时组合（1 个常数项 + 11 个预测信号），将这 12 个权重分别乘以对应的 t-1 月末信号值再求和，就得到 t 月对价值因子的配置权重。对全部四个因子执行同样的操作，便还原出 4×1 的因子权重向量 h_t。这一步等价于将 48×1 的 w 重排为 4×12 的矩阵 B，再计算：

$$h_t = B\, z_{t-1}$$

最后，论文将 h_t 按绝对值归一化，使每个月所有因子的绝对权重之和恒等于 1。这一约束的含义和作用将在 3.3 第三层中说明。

有关分析师的申明，见本报告最后部分。其他重要信息披露见分析师申明之后部分，或请与您的投资代表联系。并请阅读本证券研究报告最后一页的免责申明。

至此，整个链条闭合。训练窗口内 w 是固定的，但由于信号值 z_{t-1} 每月都在变化，因子权重 h_t 也随之动态调整——这正是策略择时能力的来源。模型不需要每月重新优化，只需将当月末的信号值代入上述映射，即可自动生成新一期的因子配置。

3.3 三层收缩机制：抑制高维环境下的过拟合风险

3.2 给出的最优权重形式忽略了估计误差。在高维环境下，均值向量 $\hat{\mu}$ 和协方差矩阵 $\hat{\Sigma}$ 的估计噪声会直接进入优化结果——历史上看似有效的择时机会中很大一部分其实只是统计噪声，当择时组合数量从 48 扩展到上千、上万时，这些噪声足以将优化结果推向极端权重，使策略在样本外快速失效。论文为此设计了三层收缩机制，每一层针对不同来源的误差。

第一层针对协方差矩阵的估计稳定性。当择时组合数量多达上千甚至上万个时，样本协方差矩阵的估计会极度不稳定，甚至出现不可逆的情况。论文采用 Ledoit 和 Wolf（2003）提出的方法，将样本协方差矩阵向一个更简单、更稳定的目标结构（对角元素为所有组合平均方差的对角矩阵）收缩，两者之间的最优混合权重由公式自动确定，无需人工调参。为简化记号，经收缩后的协方差矩阵下文仍记为 $\hat{\Sigma}$。

第二层针对权重估计，是论文最核心的技术贡献。其核心思想是对“择时究竟能带来多少收益”保持先验怀疑：在统计推断中，先验上将所有择时信号对应的权重都压向零，数据只有在提供足够证据时才能把权重推离零值。经此修正后的最优权重为：

$$w = \left(\hat{\Sigma} + \frac{\lambda}{T} \cdot \left[0_K, 0;\ 0, \hat{D}\right]\right)^{-1} \hat{\mu}$$

各符号含义如下。$\hat{\Sigma}$ 和 $\hat{\mu}$ 含义同前。中间方括号内是一个分块对角矩阵：左上角的零块对应原始因子，即各因子常数项所对应的权重，因此不对这部分施加额外惩罚，其值完全由数据决定；右下块 $\hat{D}$ 为一个对角矩阵，对角元素为各择时组合（不含原始因子部分）自身的方差——这样的设计使得惩罚力度与各组合的波动率成比例，避免因组合间尺度差异导致的不均匀收缩。λ 为收缩超参数（论文原文记为 κ），T 为训练期长度：λ 越大，择时信号对应的权重被压得越接近零，策略越偏向静态配置；λ 越小，模型越信任数据、越积极地利用择时信号。将 λ 除以 T 则使惩罚力度随训练样本增加自动减弱——数据越充分，模型越可以放松先验约束。

两个极端情形有助于理解这个公式：λ = 0 时惩罚项消失，公式退化为 3.2 所述的无收缩形式；λ → ∞ 时所有择时信号的权重被压为零，策略完全退化为一个仅使用原始因子的静态均值方差最优组合。λ 的具体取值通过扩展窗口验证集调优，详见 3.4。

第三层针对实盘可执行性。前两层解决的是权重估计的精度问题，但输出的权重在总绝对敞口上仍可能大幅波动，带来额外的杠杆风险。在报告的表述中，可将 3.2 中对 h_t 的绝对值归一化（即所有因子的绝对权重之和恒等于 1）理解为一层独立约束——它将策略的本质明确限定为因子轮动：模型只决定因子之间的相对配比，不决定总杠杆水平。这既避免了极端仓位，也让策略可以直接作为因子轮动层叠加到基准组合之上。

三层机制各自对应不同层面的问题，缺一不可。论文的消融实验显示，当择时组合仅有 48 个时，第二层收缩的边际增益相对有限；但当组合扩展至 18,209 个时，取消第二层收缩会导致策略大幅退化——扣费后夏普比率仅剩 0.21，远低于静态最优策略的 1.22（静态最优策略不涉及择时调仓，不产生这部分额外交易成本）。具体对比见图 3 Panel B。

有关分析师的申明，见本报告最后部分。其他重要信息披露见分析师申明之后部分，或请与您的投资代表联系。并请阅读本证券研究报告最后一页的免责申明。

3.4 实证实施：扩展窗口训练与验证集超参数调优

3.2 和 3.3 给出的估计方法需要确保所有参数估计和超参数选择均仅使用决策时点之前的可用信息，以严格避免前瞻偏差。论文采用扩展窗口方案，将数据划分为训练、验证和样本外三个阶段。

以首轮为例：训练期从 1965 年 1 月开始，前 240 个月（至 1984 年 12 月）用于估计均值向量 $\hat{\mu}$ 和协方差矩阵 $\hat{\Sigma}$；紧接着的 12 个月（1985 年 1–12 月）为第一段验证期，用于在一组候选值中选出在验证集上表现最优的收缩参数 λ；再往后的 12 个月（1986 年 1–12 月）为第一段样本外期，基于选定的 λ 和训练期估计的 $\hat{\mu}$、$\hat{\Sigma}$ 计算组合表现，这部分数据在训练和验证中完全不可见，构成真正的样本外检验。此后逐年向前滚动：训练窗口每年扩展 12 个月，验证集同步新增一个 12 个月的验证块。这种累积式验证设计使 λ 的选择能够利用所有已有验证期的综合表现，降低单一验证窗口可能带来的偶然性（图 2）。论文报告的所有业绩指标均来自 1986 年 1 月至 2022 年 12 月的样本外数据拼接。

图 2：训练、验证与样本外期间划分：扩展窗口训练 + 滚动验证集调优超参数

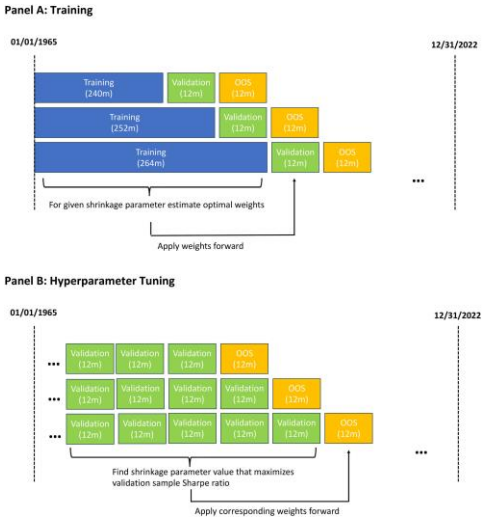

数据来源：东方证券研究所 &《Optimal Factor Timing in a High-Dimensional Setting》

4、亮点分析：相较已有因子择时方法的主要突破

相较已有因子择时研究，本文的核心增量体现在四个方面。

4.1 从单一信号扩展到多维信号融合

此前的因子择时研究大多只使用一到两个预测变量，例如 Asness 等（2017）仅用 value spread（因子多头组与空头组之间的账面市值比差值，用于衡量因子当前的估值离散程度），Gupta and Kelly（2019）仅用因子动量，Haddad、Kozak 和 Santosh（2020）虽将择时对象扩展到因子主成分，但预测信号仍限于 value spread 一种。这些方法的共同局限在于，单一类别的信号难以同时捕捉宏观经济环境变化与因子自身动态对收益的联合影响，样本外效果往往不够稳健。本文将宏观变量和因子特有变量同时纳入统一框架，消融实验（图 3 Panel A）显示，两类信号具有明显互补性：任一类别单独移除后夏普比率均出现显著下降，仅用单一信号时表现接近不做任何择时的等权策略水平，说明两类信号缺一不可。

有关分析师的申明，见本报告最后部分。其他重要信息披露见分析师申明之后部分，或请与您的投资代表联系。并请阅读本证券研究报告最后一页的免责申明。

4.2 将因子择时直接改写为组合优化问题

此前的因子择时研究大致可分为两类：一类是“先预测、再配置”的两步法，即先用回归或机器学习模型预测各因子下期收益，再以预测值为输入做组合优化，两步估计误差会叠加放大；另一类是启发式组合规则，例如 Neuhierl 等（2023）用多个预测变量生成因子收益预测后按排序选股、Kagkadis 等（2024）采用启发式组合、Dichtl 等（2019）依赖人为设定的主成分降维，这些方法要么不涉及正式的组合优化，要么以牺牲信号完整性为代价压缩维度。

本文的做法从根本上不同。通过将因子收益与滞后信号相乘构造择时组合，论文把原本的动态择时问题转化为在一组固定择时组合上求解最优权重的静态问题——这使得该问题可以直接放入 Markowitz 式的组合优化框架中处理，组合优化领域积累的成熟工具（协方差估计、贝叶斯先验、正则化等）也可以被直接移植到因子择时场景，无需重新构造一套方法论。相较于更常见的“先预测、再配置”两步法或启发式排序法，本文将因子择时直接改写为组合优化问题的表述更少见，也更具方法论特色。

4.3 高维组合优化框架内引入数据驱动的收缩机制

论文在均值方差优化框架内，通过三层收缩自适应调节对信号的信任程度：训练数据少时收缩力度大、策略偏保守，数据充分后收缩自然放松、策略逐步释放择时信号的潜力。同时，因子轮动约束将策略总敞口固定为 1，避免极端杠杆，使优化结果在实盘中可以直接执行。收缩机制还带来了一个额外好处：在高维设定下的大预测集场景中，收缩同时显著降低了换手率（图 3 Panel B），有收缩与无收缩的交易成本差距接近 5 倍。这种机制使得框架在从 48 个到 18,209 个择时组合的不同规模下都保持有效。

4.4 验证了大盘股因子同样存在显著的择时空间

标准 Fama-French 因子对小盘股赋予了较大权重，因此一个常见质疑是择时收益可能依赖于小盘股的流动性溢价，实盘中难以实现。论文构建了仅使用 NYSE 市值中位数以上股票的因子版本，结果显示择时策略的改善幅度与标准版基本一致，且尾部风险也显著改善（详见 5.1 节），削弱了“小盘股驱动”的可能性，也为大盘风格为主的 A 股量化实践提供了更直接的参考。

图 3：消融实验汇总——信号融合与收缩机制的边际贡献

Panel A：预测变量消融（FF 四因子，小预测集，48 个择时组合）

配置	样本外夏普比率	相对完整模型的变化
全部变量（宏观 + 因子特有）	0.81	——
去掉宏观变量（仅保留因子特有变量）	0.67	−0.14
去掉因子特有变量（仅保留宏观变量）	0.48	−0.33
仅用 value spread 或动量单一信号	0.49	−0.32
等权策略（不做任何择时）	0.42	−0.39

Panel B：权重收缩消融（Jensen 等 131 因子，大预测集，18,209 个择时组合）

配置	样本外夏普比率	年化换手率	年化成本(bps)	扣费后夏普比率
有收缩（λ 由验证集选取）	1.43	2.36	24	1.31
无收缩（λ = 0）	0.81	11.12	111	0.21
静态最优策略（不择时）	1.22	—	—	—

数据来源：东方证券研究所 &《Optimal Factor Timing in a High-Dimensional Setting》

有关分析师的申明，见本报告最后部分。其他重要信息披露见分析师申明之后部分，或请与您的投资代表联系。并请阅读本证券研究报告最后一页的免责申明。

5、 实证结果：样本外夏普比率显著提升，择时策略表现稳健

论文的实证检验覆盖了 1986 年 1 月至 2022 年 12 月的样本外期间，所有业绩指标均基于前述扩展窗口方案逐年滚动生成，不存在前瞻偏差。以下分别从策略表现和成本可行性两个角度展开讨论。

5.1 三档因子集合样本外表现：择时策略一致跑赢静态基准

从整体结果来看，无论因子规模大小，择时策略都显著优于不择时基准，改善幅度在不同因子集合上具有高度一致性。择时策略相对静态最优策略的夏普比率增量稳定在 0.25 至 0.30 之间，相对等权策略则基本实现翻倍。

具体而言，Fama-French 四因子择时策略的样本外夏普比率为 0.81，高于等权策略的 0.42 和静态最优策略的 0.52。评估比率为 0.79，与夏普比率接近，说明策略的收益几乎全部来自因子择时本身，而非承担市场方向性风险。在尾部风险方面，择时策略最差 12 个月收益仅为 −5.62%，远优于等权策略（−13.77%）和静态策略（−17.24%）。从 60 个月滚动窗口来看，择时策略在绝大多数时段均跑赢静态和等权策略，仅在 2003 至 2008 年间的部分窗口与静态策略持平。值得注意的是，样本最后五年（2017 至 2022 年）的相对优势不减反增，表明择时收益并未随时间衰减（图 4）。

论文指出，择时策略在 1999 年、2007 年和 2020 年初分别主动降低了对价值因子的暴露，从而有效规避了价值因子在这几个阶段的重大回撤（图 5）。

图 4：Fama-French 因子组合样本外夏普比率（60 月滚动窗口）：择时策略几乎全程跑赢

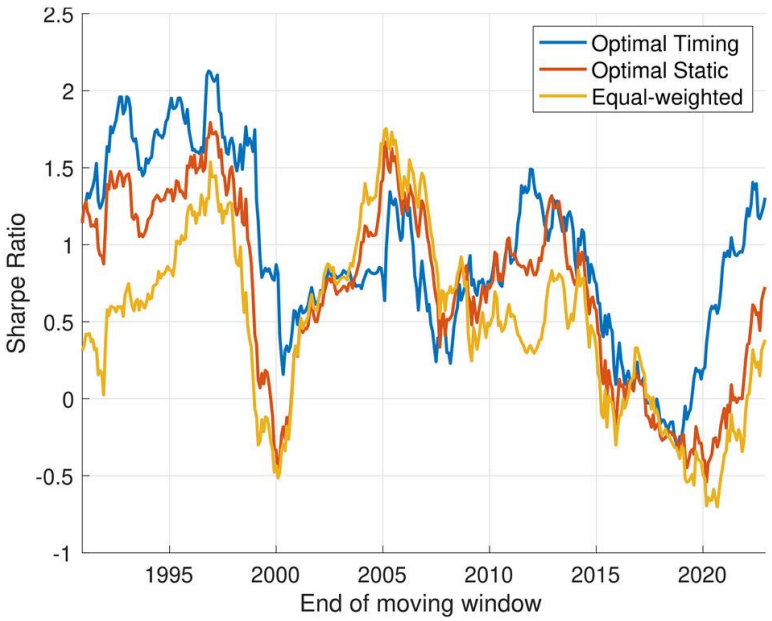

数据来源：东方证券研究所 &《Optimal Factor Timing in a High-Dimensional Setting》

有关分析师的申明，见本报告最后部分。其他重要信息披露见分析师申明之后部分，或请与您的投资代表联系。并请阅读本证券研究报告最后一页的免责申明。

图 5：择时策略对 Fama-French 四因子的隐含权重变化：1999/2007/2020 年主动降低价值因子敞口

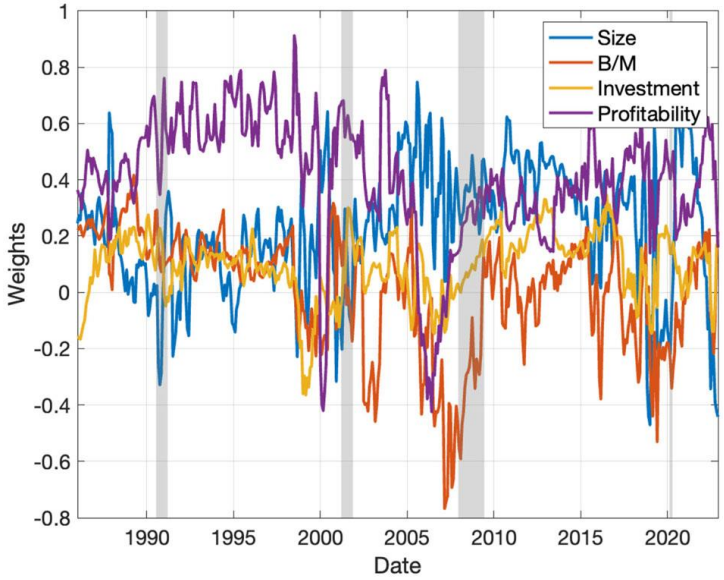

数据来源：东方证券研究所 &《Optimal Factor Timing in a High-Dimensional Setting》

大盘版测试仅使用 B/M、盈利能力和投资三个因子，对应 36 个择时组合。大盘版因子择时策略夏普比率为 0.56，等权策略为 0.26，静态最优策略为 0.30，择时相对等权的改善幅度与标准版基本一致，均约为翻倍。在尾部风险方面，大盘版择时策略的最差 12 个月收益为 −13.70%，远优于等权策略（−26.84%）和静态策略（−26.90%），说明择时不仅提升了收益，也有效控制了极端回撤。从 60 个月滚动窗口来看，大盘版择时策略几乎完全避免了出现负夏普比率的情形，且近 15 年相对优势尤为突出，进一步说明择时收益并非仅由小盘股驱动（图 6）。

图 6：大盘版因子样本外夏普比率（60 月滚动窗口）：择时仍实现夏普比率翻倍

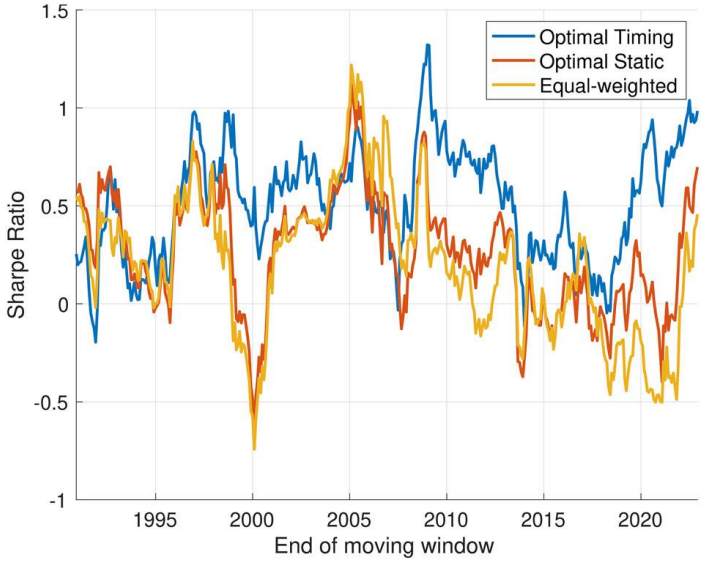

数据来源：东方证券研究所 &《Optimal Factor Timing in a High-Dimensional Setting》

有关分析师的申明，见本报告最后部分。其他重要信息披露见分析师申明之后部分，或请与您的投资代表联系。并请阅读本证券研究报告最后一页的免责申明。

Jensen 等（2023）131 因子择时策略夏普比率达到 1.48，高于静态最优策略的 1.22。当预测变量进一步扩展至 139 个、择时组合总量达到 18,209 个时，夏普比率为 1.43，与小预测集基本持平，说明扩大预测变量集合后未显示出明显额外增益（图 7）。

多预测变量的消融实验也验证了信号融合的必要性：去掉宏观变量或因子特有变量中的任何一类，夏普比率均出现明显下降；仅使用单一信号时，表现接近不做任何择时的等权策略水平。

图 7：Jensen 等因子样本外夏普比率（60 月滚动窗口）：高维设定下夏普比率达 1.48

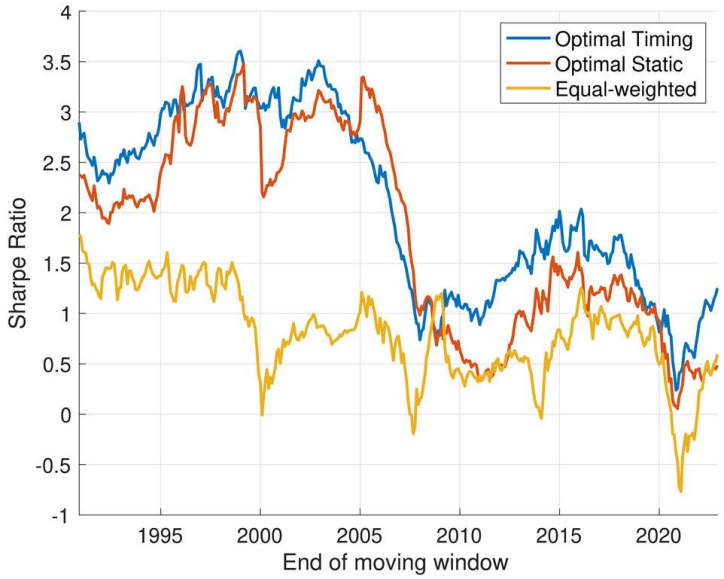

数据来源：东方证券研究所 &《Optimal Factor Timing in a High-Dimensional Setting》

5.2 收缩显著降低换手率，扣费后策略仍优于基准

择时策略涉及因子权重的动态调整，不可避免地会产生交易成本。论文基于 Frazzini、Israel 和 Moskowitz（2018）对大型机构实际交易数据的估计，按每笔交易约 10 个基点的成本进行测算。

结果显示，不同因子集合的换手率差异显著。Fama-French 因子择时策略（小预测集，48 个择时组合）的年化双边换手率约为 5.86，对应年化交易成本约 59 个基点，扣费后夏普比率从 0.81 降至 0.71，仍明显高于对应静态策略的 0.52。Jensen 等 131 因子择时策略（同为小预测集，1,572 个择时组合）的换手率则低得多，仅为 2.50，对应年化成本约 25 个基点，扣费后夏普比率从 1.48 降至 1.35。论文还指出，上述成本估计偏保守，原因有二：一是不同因子之间的调仓方向可能相互抵消，实际需要交易的净头寸低于理论换手量；二是因子本身定期调整成分股时产生的交易，与择时带来的权重调整存在部分重叠，不应重复计算。

收缩机制在控制换手率方面同样发挥了重要作用。以 Jensen 等 131 因子搭配大预测集（139 个预测变量，18,209 个择时组合）为例，施加收缩后年化换手率为 2.36，年化成本 24 个基点，扣费后夏普比率为 1.31；若取消收缩（令 λ=0），换手率飙升至 11.12，年化成本升至 111 个基点，扣费后夏普比率仅剩 0.21。这一对比表明，在高维设定下，收缩既改善了策略表现，也显著降低了交易成本，是策略能够稳定落地的重要保障。

有关分析师的申明，见本报告最后部分。其他重要信息披露见分析师申明之后部分，或请与您的投资代表联系。并请阅读本证券研究报告最后一页的免责申明。

图 8：交易成本调整后表现：Jensen 等因子择时扣费后夏普比率仍达 1.31-1.35，收缩显著降低换手率

Table 3. Adjustment for Trading Costs

	Number of Timing Portfolios	Annualized 2-way Turnover	Annual Cost (bps)	Sharpe Ratio After Cost	Sharpe Ratio Before Cost
Timing Fama-French factors	48	5.86	0.59	0.71	0.81
Variant: No shrinkage (lambda = 0)	48	6.16	0.62	0.72	0.82
Timing large cap version of Fama-French factors	36	6.40	0.64	0.46	0.56
Variant: No shrinkage (lambda = 0)	36	7.90	0.79	0.39	0.52
Timing Jensen et al. factors, small set of predictors	1,572	2.50	0.25	1.35	1.48
Variant: No shrinkage (lambda = 0)	1,572	9.47	0.95	0.72	1.21
Timing Jensen et al. factors, large set of predictors	18,209	2.36	0.24	1.31	1.43
Variant: No shrinkage (lambda = 0)	18,209	11.12	1.11	0.21	0.81

Notes: Sharpe ratios are annualized.

数据来源：东方证券研究所 &《Optimal Factor Timing in a High-Dimensional Setting》

6、 改进方向：贴合 A 股特性，多维度升级实现本土化落地

A 股市场风格轮动节奏较快，因子收益阶段性波动明显。在此背景下，若能在现有多因子选股体系之上嵌入系统性的因子择时层，有望更有效地控制因子失效阶段的组合回撤，提升整体风险收益比。论文的方法论框架具有较强的通用性，但实证分析完全基于美股数据，在因子构造、预测变量选取、市场结构和交易制度等方面与 A 股存在显著差异。若要将该框架应用于国内市场，需要在以下四个方向进行针对性的适配与改进。

6.1 丰富预测变量体系，融入 A 股特色信号

论文使用的 5 个宏观变量（国债收益率、收益率曲线斜率、利率变化、市场近期收益、信用利差）均来自美国市场，直接平移至 A 股存在适配性不足的问题。A 股市场的风格轮动受到一些美股中不存在或影响较弱的因素驱动，在预测变量的选取上有必要做出相应调整。

宏观层面，建议纳入与 A 股风格切换关联较强的本土信号，包括社会融资规模增量、M2 与 M1 增速差、PMI 分项指标、北向资金净流入、以及两融余额变化等。这些变量在国内研究中较常被用作候选信号，可进一步检验其对 A 股风格轮动和因子表现的预测作用。

因子特有层面，论文使用了因子动量、波动率和三个基础特征差值。在此基础上，建议进一步引入因子拥挤度指标（如因子持仓重叠度或因子估值分位数的极端程度），以捕捉因子收益可能出现均值回复的时点。此外，A 股市场的涨跌停板制度和 T+1 交易规则使得因子收益分布呈现不对称特征，可考虑加入刻画这种非对称性的辅助变量。

6.2 引入非线性模型扩展择时能力

论文的因子择时组合本质上是预测变量与因子收益的线性交互项，隐含假设为预测关系在不同市场状态下是稳定的。然而 A 股市场的风格切换往往具有非线性特征：因子收益与宏观变量之间的关系可能在不同市场状态下表现出截然不同的模式。例如，收益率曲线斜率对价值因子的预测能力在正常市场环境与极端风险事件中的方向和强度可能完全不同。

在保持论文线性优化框架不变的前提下，可以通过两种方式引入非线性信号。第一种是对预测变量进行变换后再构造择时组合，例如加入预测变量的平方项和交叉项，或将预测变量分箱后

有关分析师的申明，见本报告最后部分。其他重要信息披露见分析师申明之后部分，或请与您的投资代表联系。并请阅读本证券研究报告最后一页的免责申明。

构造哑变量交互，使模型能够捕捉阈值效应和状态依赖关系。第二种是借鉴 DiCiurcio 等（2024）提出的两阶段框架，先通过无监督学习将市场划分为不同风险状态（如正常、修正、熊市），再在每种状态下分别估计择时模型参数，使得信号权重能够随市场状态自适应调整。

6.3 构建 A 股因子池并适配因子构造方式

论文使用的 Fama-French 因子和 Jensen 等（2023）因子均基于美股数据构造，在选股范围、分组方式和加权方法上与 A 股的常见做法存在差异。若直接照搬美股因子定义，可能无法充分反映 A 股市场的截面收益结构。

建议从三个方面进行适配。第一，分别基于 A 股全市场、沪深 300 和中证 500 构建多空因子，评估择时效果在不同市值域中的差异性。第二，在执行择时之前对因子收益进行行业和市值中性化处理，剥离系统性风格暴露的干扰，确保择时信号反映的是纯粹的因子 alpha 而非行业或市值 beta。第三，在因子数量上可先从 A 股实证中使用较为成熟的 10 至 20 个核心风格因子起步（涵盖价值、成长、动量、反转、波动率、质量、流动性等维度），待框架验证通过后再逐步扩展至更大规模的因子池。

6.4 缩短验证窗口并纳入换手率约束，适配 A 股风格切换节奏

论文使用 12 个月固定长度的验证块来选择 λ，并采用累积式验证集汇总历史表现。这一方案在美股长达 57 年的月度数据支持下运行良好，但 A 股的有效数据历史较短（通常从 2005 年股权分置改革后起算），且风格切换节奏更快，直接套用同样的验证框架可能不够灵活。

建议从三个方面加以优化。第一，缩短验证块长度至 6 个月甚至采用月度滚动验证，以更快地捕捉 A 股风格切换信号，避免因验证窗口过长而滞后于市场变化。第二，在以夏普比率最大化为主要目标的基础上，引入信息准则（如 BIC）或交叉验证作为辅助约束，降低 λ选择本身过拟合的风险。第三，考虑对换手率施加显式约束，或将交易成本直接纳入目标函数，使优化结果在扣费后仍保持稳健表现，而不仅依赖事后的成本测算来评估策略可行性。

7、 风险提示

1. 量化模型基于历史数据分析，未来存在失效风险，建议持续跟踪模型表现。
2. 极端市场环境可能对模型效果造成显著冲击，导致收益回撤。
3. 论文实证基于美股数据，迁移至 A 股时需充分考虑市场结构和交易制度差异。
4. 因子择时策略涉及动态调仓，交易成本和流动性约束可能侵蚀部分理论收益。
5. 收缩参数 λ 的选择依赖于验证集设计，若验证集设置不当可能导致收缩不足或过度，影响策略稳健性。

有关分析师的申明，见本报告最后部分。其他重要信息披露见分析师申明之后部分，或请与您的投资代表联系。并请阅读本证券研究报告最后一页的免责申明。

分析师申明

每位负责撰写本研究报告全部或部分内容的研究分析师在此作以下声明：

分析师在本报告中对所提及的证券或发行人发表的任何建议和观点均准确地反映了其个人对该证券或发行人的看法和判断；分析师薪酬的任何组成部分无论是在过去、现在及将来，均与其在本研究报告中所表述的具体建议或观点无任何直接或间接的关系。

投资评级和相关定义

报告发布日后的 12 个月内行业或公司的涨跌幅相对同期相关证券市场代表性指数的涨跌幅为基准（A 股市场基准为沪深 300 指数，香港市场基准为恒生指数，美国市场基准为标普 500 指数）；

公司投资评级的量化标准

买入：相对强于市场基准指数收益率 15%以上；
增持：相对强于市场基准指数收益率 5%～15%；
中性：相对于市场基准指数收益率在-5%～+5%之间波动；
减持：相对弱于市场基准指数收益率在-5%以下。
未评级 —— 由于在报告发出之时该股票不在本公司研究覆盖范围内，分析师基于当时对该股票的研究状况，未给予投资评级相关信息。
暂停评级 —— 根据监管制度及本公司相关规定，研究报告发布之时该投资对象可能与本公司存在潜在的利益冲突情形；亦或是研究报告发布当时该股票的价值和价格分析存在重大不确定性，缺乏足够的研究依据支持分析师给出明确投资评级；分析师在上述情况下暂停对该股票给予投资评级等信息，投资者需要注意在此报告发布之前曾给予该股票的投资评级、盈利预测及目标价格等信息不再有效。

行业投资评级的量化标准：

看好：相对强于市场基准指数收益率 5%以上；
中性：相对于市场基准指数收益率在-5%～+5%之间波动；
看淡：相对于市场基准指数收益率在-5%以下。
未评级：由于在报告发出之时该行业不在本公司研究覆盖范围内，分析师基于当时对该行业的研究状况，未给予投资评级等相关信息。
暂停评级：由于研究报告发布当时该行业的投资价值分析存在重大不确定性，缺乏足够的研究依据支持分析师给出明确行业投资评级；分析师在上述情况下暂停对该行业给予投资评级信息，投资者需要注意在此报告发布之前曾给予该行业的投资评级信息不再有效。

有关分析师的申明，见本报告最后部分。其他重要信息披露见分析师申明之后部分，或请与您的投资代表联系。并请阅读本证券研究报告最后一页的免责申明。

免责声明

本证券研究报告（以下简称“本报告”）由东方证券股份有限公司（以下简称“本公司”）制作及发布。

本报告仅供本公司的客户使用。本公司不会因接收人收到本报告而视其为本公司的当然客户。本报告的全体接收人应当采取必要措施防止本报告被转发给他人。

本报告是基于本公司认为可靠的且目前已公开的信息撰写，本公司力求但不保证该信息的准确性和完整性，客户也不应该认为该信息是准确和完整的。同时，本公司不保证文中观点或陈述不会发生任何变更，在不同时期，本公司可发出与本报告所载资料、意见及推测不一致的证券研究报告。本公司会适时更新我们的研究，但可能会因某些规定而无法做到。除了一些定期出版的证券研究报告之外，绝大多数证券研究报告是在分析师认为适当的时候不定期地发布。

在任何情况下，本报告中的信息或所表述的意见并不构成对任何人的投资建议，也没有考虑到个别客户特殊的投资目标、财务状况或需求。客户应考虑本报告中的任何意见或建议是否符合其特定状况，若有必要应寻求专家意见。本报告所载的资料、工具、意见及推测只提供给客户作参考之用，并非作为或被视为出售或购买证券或其他投资标的的邀请或向人作出邀请。

本报告中提及的投资价格和价值以及这些投资带来的收入可能会波动。过去的表现并不代表未来的表现，未来的回报也无法保证，投资者可能会损失本金。外汇汇率波动有可能对某些投资的价值或价格或来自这一投资的收入产生不良影响。那些涉及期货、期权及其它衍生工具的交易，因其包括重大的市场风险，因此并不适合所有投资者。

在任何情况下，本公司不对任何人因使用本报告中的任何内容所引致的任何损失负任何责任，投资者自主作出投资决策并自行承担投资风险，任何形式的分享证券投资收益或者分担证券投资损失的书面或口头承诺均为无效。

本报告主要以电子版形式分发，间或也会辅以印刷品形式分发，所有报告版权均归本公司所有。未经本公司事先书面协议授权，任何机构或个人不得以任何形式复制、转发或公开传播本报告的全部或部分内容。不得将报告内容作为诉讼、仲裁、传媒所引用之证明或依据，不得用于营利或用于未经允许的其它用途。

经本公司事先书面协议授权刊载或转发的，被授权机构承担相关刊载或者转发责任。不得对本报告进行任何有悖原意的引用、删节和修改。

提示客户及公众投资者慎重使用未经授权刊载或者转发的本公司证券研究报告，慎重使用公众媒体刊载的证券研究报告。

东方证券研究所

地址： 上海市中山南路 318 号东方国际金融广场 26 楼

电话： 021-63325888

传真： 021-63326786

网址： www.dfzq.com.cn

东方证券股份有限公司经相关主管机关核准具备证券投资咨询业务资格，据此开展发布证券研究报告业务。
东方证券股份有限公司及其关联机构在法律许可的范围内正在或将要与本研究报告所分析的企业发展业务关系。因此，投资者应当考虑到本公司可能存在对报告的客观性产生影响的利益冲突，不应视本证券研究报告为作出投资决策的唯一因素。